

Sosyal Medya Görsellerinde Marka Logosu Tespiti

Brand Logo Detection in Social Media Images

Özgün Yargı^{1,2}, Aksel Dindisyan¹, Onur Varol^{1,2}

¹Sabancı Üniversitesi ²Viral Teknoloji

{ozgunyargi,aksel.dindisyan,onur.varol}@sabanciuniv.edu

Özetçe—Sosyal medya platformlarında paylaşılan görsellerde logolar çoğu zaman içeriğin ana odağında yer almasa da marka görünürlüğü açısından kritik sinyaller üretmektedir. Literatürde yaygın kullanılan açık veri setleri sosyal medya gönderilerindeki bağlam çeşitliliğini, arka plan karmaşıklığını ve küçük/kısmi örtülü logo örneklerini sınırlı düzeyde yansıttığı için mevcut veriyle eğitilen modeller gerçek sosyal medya koşullarında genelleme sorunu yaşayabilmektedir. Bu çalışmada Türkiye’de yaygın kullanılan 25 markayı kapsayan sosyal medya odaklı bir logo tespit veri seti sunulmaktadır. Veri toplama ve etiketleme süreci kalite güvencesi perspektifiyle yürütülmüş; etiketleyici davranışları, oturum dinamikleri ve etiketleme tutarlılığı sistematik olarak analiz edilmiştir. Süreç sonunda 5,087 görsel ve 9,731 logo etiketi içeren bir veri seti oluşturulmuştur. Çalışmanın ana odağı, eğitim verisinin kaynağının model başarımına etkisini ölçmektir. Bu kapsamda sosyal medya veri setimiz üzerinde eğitilen bir model ile Flickr’dan toplanmış bir veri setinde eğitilen model, karşı veri setlerinin değerlendirme kümelerinde test edilmiştir. Sosyal medya verisiyle eğitilen modelin hem alan içi hem de alanlar arası senaryoda daha yüksek genelleme ve başarımlar sergilediğini gösterilmektedir.

Anahtar Kelimeler—marka logosu tespiti, sosyal medya analitiği, veri seti oluşturma, kalite kontrollü etiketleme, nesne tespiti

Abstract—Although logos in social media images are often not the focal in the post, they provide critical signals for measuring brand visibility. Existing open logo benchmarks partially reflect social-media-specific challenges such as highly diverse contexts, cluttered backgrounds, and small or partially occluded logos, which can limit model generalization in real deployments. In this work, we present a social-media-focused logo detection dataset covering 25 widely used brands in Türkiye. The data collection and annotation pipeline was designed with quality assurance, including analyses of annotator behavior, session dynamics, and label consistency. The resulting dataset contains 5,087 images and 9,731 logo instances. Our main objective is to quantify the impact of training data source on detection performance. We therefore compare a model trained on our social media dataset against a model trained on a Flickr dataset, and evaluate each model on the other dataset’s evaluation split. Cross-dataset results show that the social-media-trained model achieves stronger in-domain performance and better out-of-domain generalization, indicating higher robustness for social media logo detection.

Keywords—brand logo detection, social media analysis, dataset construction, quality-controlled annotation, object detection

I. GİRİŞ

Sosyal medyada paylaşılan görsel içeriklerin hacmi artarken, gönderilerde çoğu odakta olmayan marka logoları da geniş kitlelere ulaşmaktadır ve markalar açısından yal-

nızca reklam içerikleri değil, pasif logo görünürlüğünün de ölçülmesi stratejik bir ihtiyaç haline gelmiştir.

Marka görünürlüğünü insan eforuyla incelemek, veri ölçeği ve çeşitliliği nedeniyle sürdürülebilir değildir; bu nedenle nesne tespiti tabanlı otomatik yöntemler öne çıkmaktadır. Yöntemlerin başarımı ise eğitildikleri verinin temsiliyeti ile doğrudan bağlıdır. Sosyal medya görüntülerinde sık görülen düşük çözünürlük, kısmi örtülme, metin bindirmeleri ve karmaşık arka plan gibi koşullar genel amaçlı veri setleriyle eğitilen modeller için zorluk oluşturmaktadır.

Bu çalışmanın temel sorusu, eğitim verisinin logo tespit performansı ve genelleme kapasitesi üzerindeki etkisidir. Bu amaçla Türkiye’de yaygın kullanılan 25 markayı kapsayan sosyal medya odaklı bir veri seti oluşturulmuş; veri toplama ve etiketleme süreci kalite güvencesi yaklaşımıyla izlenmiştir. Süreç sonunda 5,087 görsel ve 9,731 logo etiketinden bir veri seti elde edilmiştir. Ağırlıklı sınırlayıcı kutu kaynaştırması (Weighted Box Fusion, kısaca WBF) yöntemi kullanılarak kullanıcı etiketlerinden referans kutular (ground truth) oluşturulmuştur. Bu referanslarla kıyaslanarak etiketleyici performansını etkileyen faktörler de incelenmiştir.

Deneyisel tasarımda aynı model mimarisi kullanılarak sosyal medya veri setimiz ve yaygın kullanılan Flickr veri setinde eğitilen modeller kıyaslanmıştır. Analizlerde çapraz değerlendirme yaklaşımı ile alan içi başarıma ek olarak alanlar arası genelleme ve dayanıklılık doğrudan ölçülmüştür.

Elde edilen bulgular, sosyal medya verisiyle eğitilen modelin Flickr veri setiyle eğitilen modele kıyasla daha yüksek ve tutarlı performans sergilediğini göstermektedir. Sonuçlar, logo tespit sistemlerinde veri kaynağının mimari seçim kadar belirleyici olduğunu ve sosyal medya veri setinin gerçek kullanım koşullarında daha güçlü genelleme sağladığını göstermektedir.

II. LİTERATÜR TARAMASI

Marka logosu tespitiyle nesne tespiti literatüründeki gelişmelerle doğrudan ilişkilidir ve R-CNN ailesi gibi iki aşamalı yaklaşımlar yüksek doğruluk sağlarken, hesaplama maliyetleri nedeniyle büyük ölçekli ve gerçek zamanlı uygulamalarda sınırlı kalmıştır [1], [2]. Tek aşamalı dedektörler ise hız-doğruluk dengesini iyileştirerek logo tespiti gibi pratik uygulamalarda yaygınlaşmıştır. YOLO modelleri çok ölçekli özellik kullanımı ve eğitim süreçlerindeki iyileştirmelerle küçük nesne tespitinde duyarlılığı artırmıştır [3]–[5].

Dönüştürücü (transformer) tabanlı yaklaşımlar, küresel bağlam modelleme kabiliyeti sayesinde nesne tespitinde güçlü

bir alternatif olmuştur. DETR, tespiti uçtan uca bir küme tahmin problemi olarak ele alarak diğer yaklaşımlardaki birçok elle tasarlanmış bileşeni sadeleştirmiştir [6]. Deformable DETR, çok ölçekli dikkat mekanizmasıyla özellikle küçük nesnelerde yakınsama ve doğruluk açısından avantajlıdır [7]. DINOv2 gibi özdenetimli ön eğitimle elde edilen güçlü görsel temsillerin tespit başarımını artırdığı gösterilmiştir [8].

Model tarafındaki ilerlemelere karşın, logo tespitinde belirleyici unsurun yalnızca mimari olmadığı; eğitim verisinin niteliği ve alan uyumu olduğu giderek daha net ortaya çıkmaktadır. FlickrLogos [9] ve LogoDet-3K [10] veri setleri kıyaslamalarda kullanılsa da, bu veri setleri sosyal medya ortamındaki gürültü, çoklu logo varlığı, küçük/kısmi örtülü logolar ve karmaşık bağlamda yetersiz kalmaktadır [11]. Veri kaynağına bağlı alan kayması probleminde nesne tespiti modellerinin bağlam yanlılığını öğrendiği ve eğitim dağılımına aşırı uyum gösterebildiği bilinmektedir [12]. Dolayısıyla veri seti içinde yapılan değerlendirmeler, modelin gerçek dünyadaki genelleme kapasitesini olduğundan yüksek gösterebilir. Bu çalışmada oluşturduğumuz sosyal medya veri seti ve Flickr verisiyle eğitilen modeller test edilmekte, alan içi başarımlar ve alanlar arası dayanıklılık sistematik biçimde incelenmektedir.

III. VERİ SETİ OLUŞTURMA VE KALİTE ANALİZİ


Nesne tespit sistemlerinde bağlam yanlılığı ön/arka plan korelasyonlarından kaynaklanmaktadır. Modelin dayanıklılığını ve genelleme yeteneğini artırmak için eğitim verisinin her nesne sınıfı açısından farklı sahne bağlamlarını içermesi gerekmektedir [12]. Bu sebeple farklı marka logoları için yüksek ortam çeşitliliğini sağlamanın etkili yollarından birinin sosyal medya içeriklerinden yararlanmak olduğu değerlendirilmiştir.

Veri toplama ve etiketleme süreci boyunca sosyal medyayı aktif kullanan 25 üniversite öğrencisinin her birinden; gıda, giyim, spor ve teknoloji gibi farklı endüstrileri kapsayacak 25 farklı markadan yalnızca birisi için, en az 200 görsel toplanması istenmiştir. Bu şekilde, aynı görsellerin veri setine eklenmesi engellenmiştir. Instagram platformunda “işbirliği” etiketi içeren paylaşımlarda sık görülen ve Türkiye’de fenomenlerce kullanan markalardan bir logo veri seti oluşturulmuştur.

Bu çalışmada katılımcıların performansı, kendilerine atanan markanın görsellerini toplarken ve çalışmadaki tüm görsellerden rastgele seçilen 740 resim üzerinde logo etiketlemesi yaparken iki ayrı aşamada gerçekleşmiştir. Katılımcılara resimleri toplayabilmeleri için 15 iş günü ve sonrasında kendilerine rastgele atanan görselleri açık kaynaklı CVAT aracı [13] ile etiketlemeleri için 30 gün verilmiştir ve tüm süreçlerde kullandıkları zamanlar analiz için kayıt altına alınmıştır.

Veri seti oluşturma aşamasında 5,087 görsel toplanmıştır. Nesne tespiti aşamasında ise görsel içindeki tüm logoların konum bilgileri toplanmış ve kalitesini ölçmek için, her bir kullanıcı için oluşturulmuş partinin %70’lik kısmı, tüm katılımcılar tarafından etiketlenmiştir.

Kitle kaynaklı çalışmalarda verilen sürenin verimli ve düzenli kullanılması önemlidir [14]. Şekil 1, her katılımcının veri toplama (üst) ve etiketleme (alt) süreçlerindeki ilerleyiş ve görevi hangi zaman aralığında tamamladığını göster-




Şekil 1. Katılımcıların veri toplama (üst) ve etiketleme (alt) görevlerini tamamlama yüzdelerinin zamanla değişimi.

mektedir. Mavi ile gösterilen düzenli faaliyet, kullanıcıların kümülatif ilerleme eğrileri ile kıyaslanmaktadır. Eğrilerin eğimi, kullanıcıların görevi tamamlama temposu ile ilişkilidir.

İş yükünün büyüklüğü nedeniyle kullanıcıların görevin tamamını tek bir oturumda tamamlaması gerçekçi değildir. Bu nedenle, iki gönderi arasındaki süre 30 dakikayı aşmayacak şekilde oturumlar tanımlanmış; oturum süresi ile gönderiler arası geçen süre arasında bir ilişki olup olmadığı incelenmiştir. Şekil 2, oturum süresi arttıkça katılımcılarda veri toplama (üst) ve etiketleme (alt) performansındaki düşüş, tamamlanan işler arasındaki sürenin artmasıyla ilişkilendirilmiştir. Veri toplama aşamasında 80 dakikadan kısa oturumlarda geçen süre 23.92 ± 8.93 saniye olmaktadır ancak 120 dakika üstündeki oturumlarda ortalama süre 29.56 ± 7.41 saniyeye kadar yükselmektedir. Veri etiketleme süreçlerinde oturum süresi ile etiketleme süresi arasında doğrusal bir ilişki gözlenmektedir ve performans düşüşü daha net ortaya çıkmaktadır.

Etiketleme sürecinde performans ise katılımcıların ortak olarak etiketledikleri resimler üzerinden yapılmaktadır. Tüm katılımcılardan gelen logo alanları, Weighted Box Fusion yaklaşımı [15] ile birleştirilmektedir ve daha güvenilir sınırlayıcı kutular referans gerçek olarak kullanılmak üzere hazırlanmaktadır [16]. Bu yaklaşımda bir görsel üzerinde farklı sınırlayıcı kutuların kesişim alanının birleşime oranı olan ve $[0,1]$ arasındaki IoU değeri hesaplanır. İteratif olarak bazı kutular birleştirilmekte ve herhangi bir sınırlayıcı kutu kalmayana dek süreç devam etmektedir [16].

Kullanıcıların etiketleme süreçlerine etki eden koşulları incelemek amacıyla, analizlerden türetilen özniteliklerle bir en küçük kareler yöntemi (OLS) modeli kurulmuştur. Bağımlı değişken olarak, her bir kullanıcı etiketinin birleşik referans kutularla (ground truth) olan en yüksek IoU değeri kullanılmıştır. Bağımsız değişkenler; etiketleme zamanı (gün/saat), genel ilerleme, oturum numarası, oturum içi yüzdesel ilerleme, etiketleme süresi, etiketlenen alanın tüm resme



Şekil 2. Veri toplama (üst) ve etiketleme (alt) sürelerinin oturumda geçen toplam süre ile ilişkisi.

oranı ve uzun oturumlarda etiketlemenin 120 dakikadan sonra yapıp yapılmadığı bilgisini içermektedir.

Regresyon sonuçları, gece saatlerinde yapılan etiketlemelerde kalite düşüşü olduğunu göstermektedir ($\beta = -0.0052$, $p = 10^{-3}$). Oturum miktarının artması kaliteyi pozitif yönde etkilemektedir ($\beta = 0.0076$, $p < 10^{-3}$). Benzer şekilde, oturum içi ilerlemenin erken evresinde bir ısınma etkisi gözlenmiştir (warmup effect) ve kalite artışıyla ilişkili bulunmuştur ($\beta = 0.0079$, $p = 10^{-3}$). Ancak etiketleme işleminin oturumun 120. dakikasını aşması kalite üzerinde anlamlı ve negatif bir etki üretmektedir ($\beta = -0.0053$, $p = 0.031$). Etiketleme süresi arttıkça kalite metriklerinin düşmesi de istatistiksel olarak anlamlıdır ($\beta = -0.0034$, $p = 0.025$). Buna karşılık, haftanın günü, genel ilerleme düzeyi ve kutu alan oranı değişkenleri modelde anlamlı bulunmamıştır ($p > 0.05$). Bulgular etiketleme kalitesinin zamanlama ve oturum dinamikleriyle ilişkili olduğunu; özellikle uzun ve geç saatlerdeki oturumlarda etiketleme hatalarının arttığını göstermektedir.

Veri toplama ve etiketleme işlemlerinin sonunda, veri seti toplamda 5,087 görselden oluşmakta ve 9,731 marka logosu içermektedir. Sosyal medya verisinin paylaşılmasından doğabilecek etik sorunlardan ötürü açık bir platform yerine başlıca yazar ile iletişime geçilerek veriye erişim talep edilebilir.

IV. MODEL EĞİTİMİ

Veri setinin oluşturulmasının ardından, eğitim veri setlerinin model başarımına etkisini ölçmek amaçlanmaktadır ve karşılaştırma için marka çeşitliliği açısından yaygın FlickrLogos-27 veri seti kullanılmıştır [9]. Bu veri setindeki marka-özel etiketler kullanılarak logo tespit problemiyle uyumlu olacak düzenlenmiştir. Bu çalışmada modellerin logo tespiti 2 sınıflı bir problem olarak sunulmaktadır. Böylece hem sosyal medya veri setimiz hem de FlickrLogos-27 aynı problem tanımı altında eğitilip değerlendirilebilir hale getirilmiştir.

Tablo I
MODEL PERFORMANSI VE VERİ SETİ KIYASLAMASI.

	Metrik	Sosyal Medya	Flickr
FlickrLogos-27	AP@0.50	0.4849 (↓ 0.14)	0.6261
	AP@0.50:0.95	0.2273 (↓ 0.07)	0.3037
VRL-SM-Logo	AP@0.50	0.6131 (↑ 0.52)	0.0936
	AP@0.50:0.95	0.2554 (↑ 0.23)	0.0275

Her iki veri seti de %80'i model eğitim ve %20 performans testlerinde kullanılmak üzere ayrılmıştır. Mevcut veri setleri sıfırdan model eğitimi için yetersiz olması nedeniyle tüm deneyler ince ayar yaklaşımıyla yürütülmüş; modellerin çıkış katmanları logo olup olmasını tahmin edecek şekilde tanımlanmıştır. Ek olarak, eğitim kümesinde yatay çevirme, geometrik dönüşümler ve aydınlatma temelli artırıcılar uygulanarak modelin genelleme kapasitesi güçlendirilmiştir.

Model mimarisi olarak *DINOv3-ConvNext-Large* omurgası [17] ile *DETR* tespit başlığı [6] birleştiren sistem uygulanmaktadır. İnce ayar aşamasında DETR'nin kodlayıcı-çözücü (transformer encoder-decoder) bileşenleri korunmuş, omurga katmanları DINOv3 ile değiştirilmiş ve çıkış katmanları tek sınıflı logo tespit problemine göre yeniden tanımlanmıştır. Eğitim 200 epoch sürmüştür; *AdamW* optimize edicisi ile omurga için 1×10^{-6} , önceden eğitilmiş DETR katmanları için 5×10^{-5} , rastgele ilklendirilen katmanlar için 1×10^{-4} öğrenme oranları kullanılmıştır. Öğrenme oranı, toplam adım sayısının %3'üne karşılık gelen ısınma aşamasından sonra *cosine schedule* ile azaltılmıştır. Eğitim yığın boyutu (batch size) 4 seçilerek ve *gradient accumulation* 4 ile (etkin yığın boyutu 16) yürütülmüştür. Her 200 adımda doğrulama yapılmış ve model performansının ölçülmesinde ortalama kesinlik (average precision) IoU değerinin 0.5'ten büyük olduğu tahminler için doğru kabul edilerek AP@0.50 için en iyi model kaydedilmiştir.

Karşılaştırmanın adil olması için FlickrLogos-27 ve VRL-SM-Logo veri setleri üzerinde aynı mimari ve aynı eğitim protokolü uygulanmış, her iki senaryoda en iyi doğrulama performansına sahip ağırlıklar seçilmiştir. Böylece modeller arasındaki farkın eğitim verisiyle ilişkili olması öngörülebilmektedir. Genelleme ve dayanıklılığı ölçmek için çapraz veri seti değerlendirmesi yapılmış; her model hem kendi veri setinin test kümesinde hem de karşı veri setinin test kümesinde değerlendirilmiştir.

Veri setinin model performanslarında hem alan içi hem de alan dışında etkileri Tablo I içerisinde sunulmaktadır. Değerlendirme amacıyla hem PASCAL VOC standardı olan AP@0.50 ve COCO standardı AP@0.50:0.95 ile kıyaslama yapılmıştır. Sütunlarda modeller eğitildikleri veri setleri ile adlandırılmakta ve satırlarda ise test edildikleri veri kümeleri üzerindeki performansları raporlanmaktadır ve diyagonalde alan dışı performanslar görülmektedir.

Her iki modelinde eğitildikleri veri setleri üzerindeki performansları benzerlik göstermektedir ancak alan dışı veri setlerindeki performanslar genelleme becerisi açısından daha önemlidir. Burada VRL-SM-Logo veri seti ile eğitilen model AP@0.5:0.95 için sadece 0.07 daha az skor elde etmektedir. Ancak gerçek dünyada kullanım için sosyal medya verisine



Şekil 3. Model çıktılarında örnek sonuçlar. Moda, gıda, spor gibi kategorilerde logoların tespit edilebildiği görülmektedir.

baktığımızda mevcut Flickr veri seti üzerinde eğitilen modellerin performansı 0.23 daha az olmuştur. Sosyal medya verisiyle eğitilen modelin alan değişimine karşı daha dayanıklı olduğunu ve Flickr verisiyle eğitilen modele kıyasla daha güçlü genelleme sergilediği gözlemlenmektedir. Bu sebeple gerçek kullanım koşullarında yakın, yüksek bağlam çeşitliliği içeren senaryolarda sosyal medya odaklı eğitim stratejisi daha güvenilir bir tercih sunmaktadır.

Nicel bulgulara ek olarak, Şekil 3 VRL-SM-Logo ile eğitilen modelden alınan bir örnek sunmaktadır. Burada ham görüntü, etiketleyici kutuları, WBF ile elde edilen referans kutular ve açıklanabilirlik için ısı haritası birlikte gösterilmiştir. Bu çok katmanlı görselleştirme, modelin karar verirken hangi bölgelere odaklandığını insan etiketleriyle doğrudan karşılaştırmalı biçimde incelemeyi mümkün kılmakta; doğru tespitlerin yanı sıra, kullanıcılar tarafından etiketlenmesi beklenen 25 marka arasında yer almayan logoların da model tarafından tespit edilebildiğini, ısı haritası ve tahmin kutuları üzerinden göstermektedir ve modelin daha genel bir logo temsilini öğrenebildiğine işaret etmektedir.

V. SONUÇ

Bu çalışmada, sosyal medya bağlamında marka logosu tespiti problemi için Türkiye’de yaygın kullanılan 25 markayı kapsayan, 5,087 görsel ve 9,731 logo örneğinden oluşan VRL-SM-Logo veri seti oluşturulmuştur. Veri toplama ve etiketleme süreci yalnızca nicelik açısından değil, kalite güvencesi perspektifiyle de analiz edilmiştir. Bu yönüyle çalışma, model başarımı ile veri güvenilirliğini birlikte ele alan bütüncül bir çerçeve sunmaktadır.

Model değerlendirme aşamasında, aynı *DINOv3+DETR* mimarisi ve eğitim protokolü sosyal medya veri setimiz ve *FlickrLogos-27* üzerinde uygulanmış; ardından çapraz veri seti testi ile genelleme kapasitesi ölçülmüştür. Sosyal medya odaklı eğitimin daha dayanıklı ve daha iyi genellenebilen bir temsil ürettiği gösterilmektedir. Gerçek kullanım koşullarına yakın, bağlam çeşitliliği yüksek logo tespiti senaryolarında sosyal medya tabanlı veri setleri kritik önem taşımaktadır.

REFERANSLAR

- [1] R. Girshick, J. Donahue, T. Darrell, and J. Malik, “Rich feature hierarchies for accurate object detection and semantic segmentation,” in

Proc. of the IEEE Conf. on Computer Vision and Pattern Recognition, 2014, pp. 580–587.

- [2] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” *Advances in neural information processing systems*, vol. 28, 2015.
- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proc. of the IEEE Conf. on Computer Vision and Pattern Recognition*, 2016, pp. 779–788.
- [4] J. Redmon and A. Farhadi, “Yolov3: An incremental improvement,” *arXiv preprint arXiv:1804.02767*, 2018.
- [5] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “Yolov4: Optimal speed and accuracy of object detection,” *arXiv preprint arXiv:2004.10934*, 2020.
- [6] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, “End-to-end object detection with transformers,” in *European Conf. on Computer Vision*. Springer, 2020, pp. 213–229.
- [7] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai, “Deformable detr: Deformable transformers for end-to-end object detection,” *arXiv preprint arXiv:2010.04159*, 2020.
- [8] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby *et al.*, “Dinov2: Learning robust visual features without supervision,” *arXiv preprint arXiv:2304.07193*, 2023.
- [9] S. Romberg, L. G. Pueyo, R. Lienhart, and R. Van Zwol, “Scalable logo recognition in real-world images,” in *Proc. of the 1st ACM Intl. Conf. on Multimedia Retrieval*, 2011, pp. 1–8.
- [10] J. Wang, W. Min, S. Hou, S. Ma, Y. Zheng, and S. Jiang, “Logodet-3k: A large-scale image dataset for logo detection,” *ACM Transactions on Multimedia Computing, Communications, and Applications*, vol. 18, no. 1, pp. 1–19, 2022.
- [11] S. Hou, J. Li, W. Min, Q. Hou, Y. Zhao, Y. Zheng, and S. Jiang, “Deep learning for logo detection: A survey,” *ACM Transactions on Multimedia Computing, Communications and Applications*, vol. 20, no. 3, pp. 1–23, 2023.
- [12] N. Dvornik, J. Mairal, and C. Schmid, “Modeling visual context is key to augmenting object detection datasets,” in *Proc. of the European Conf. on Computer Vision*, 2018, pp. 364–380.
- [13] CVAT.ai Corporation, “Computer vision annotation tool (cvat).” [Online]. Available: <https://cvat.ai/>
- [14] K. Hata, R. Krishna, L. Fei-Fei, and M. S. Bernstein, “A glimpse far into the future: Understanding long-term crowd worker quality,” in *Proc. of the 2017 ACM Conference on Computer Supported Cooperative Work and Social Computing*, 2017, pp. 889–901.
- [15] R. Solovyev, W. Wang, and T. Gabruseva, “Weighted boxes fusion: Ensembling boxes from different object detection models,” *Image and Vision Computing*, vol. 107, p. 104117, 2021.
- [16] K. H. Le, T. V. Tran, H. H. Pham, H. T. Nguyen, T. T. Le, and H. Q. Nguyen, “Learning from multiple expert annotators for enhancing anomaly detection in medical image analysis,” *IEEE Access*, vol. 11, pp. 14 105–14 114, 2023.
- [17] O. Siméoni, H. V. Vo, M. Seitzer, F. Baldassarre, M. Oquab, C. Jose, V. Khalidov, M. Szafraniec, S. Yi, M. Ramamonjisoa *et al.*, “Dinov3,” *arXiv preprint arXiv:2508.10104*, 2025.